

Araştırma Makalelerinde Bibliyografya Halüsinasyonlarının LLM Tabanlı Tespiti: Çok Modelli Karşılaştırmalı Değerlendirme ve RAG Ablasyonu BGK601 – Final Raporu

Novruz Amirov (707241004)
İstanbul Teknik Üniversitesi
Siber Güvenlik Mühendisliği ve Kriptografi Ana Bilim Dalı
Ders Koordinatörü: Prof. Dr. Kemal Bıçakçı

31 Mayıs 2026 —Bahar 2025–2026

Özet (Executive Summary)

Büyük dil modellerinin (LLM) akademik metin üretiminde yaygınlaşmasıyla birlikte, bu modellerin ürettiği bibliyografya bölümlerinde var olmayan veya hatalı atılan kaynakların (bibliyografya halüsinasyonları) görülme sıklığı ciddi bir akademik bütünlük sorunu oluşturmuştur. Bu çalışmada, akademik referanslarda beş farklı halüsinasyon türünü (H1: tamamen uydurma referans, H2: metadeta halüsinasyonu, H3: semantik uyumsuzluk, H4: kronolojik halüsinasyon, H5: doğru referans/negatif) ayırt eden 300 örnekle özgün bir benchmark veri kümesi tasarlanmış ve dört LLM üzerinde sistematik bir karşılaştırma yürütülmüştür: iki kapalı kaynak API modeli (GPT-4o, GPT-4o-mini) ile iki açık kaynak yerel model (Llama 3.1-8B, Qwen2.5-7B, Ollama üzerinde Apple M2 Pro/16 GB birleşik bellek). Açık kaynak modellere ayrıca CrossRef tabanlı bir RAG (retrieval-augmented generation) katmanı uygulanmış; istatistiksel anlamlılık bootstrap güven aralıkları ve McNemar testleriyle raporlanmıştır.

Ana bulgular: ikili halüsinasyon tespiti F1 skoru GPT-4o için **0.911** (en yüksek), Qwen2.5-7B için **0.071** (en düşük) olarak ölçülmüştür. RAG entegrasyonu, açık kaynak modellerde ortalama $\Delta F1 = +0.320$ kazanım sağlamış (Llama: +0.231, Qwen: +0.409); RAG'li Llama'nın F1'i **0.792**'ye yükselerek GPT-4o-mini'ye (0.862) *0.07 puanlık* bir farka yaklaşmıştır. Tüm modellerde JSON ayıkla- bilirligi %100, çalıştırmalar arası tutarlılık (Fleiss κ) 0.90 ile 1.00 aralığındadır. Maliyet-başarım ekseninde GPT-4o-mini (\$0.0003/doğru karar) en verimli kapalı kaynak; açık kaynak modeller sıfır marjinal maliyetle yerel olarak çalıştırılabilmektedir. Tüm pairwise farklar McNemar testiyle istatistiksel olarak anlamlıdır ($p < 0.01$).

Anahtar Kelimeler: LLM değerlendirmesi, halüsinasyon tespiti, bibliyografya, RAG, akademik bütünlük, CrossRef, ChromaDB.

Giriş ve Motivasyon

Büyük dil modelleri (Large Language Models, LLM), araştırma destek süreçlerinin — yazım, özetleme, kaynak tarama — ayrılmaz bir bileşeni hâline gelmiştir. Vaswani ve ark. tarafından önerilen Transformer mimarisi [1] ve onu izleyen ölçekli ön-eğitim paradigması [2, 3], bu modellerin doğal dil üretimindeki başarısını beklentilerin üzerine çıkarmış; ancak bu başarının yanında *halüsinasyon* adı verilen sistematik bir hata sınıfı da gün yuzune çıkmıştır. Ji ve ark. halüsinasyonu, “modelin kendi parametrik bilgisinden veya verili kaynaktan sapan, doğrulanabilir biçimde yanlış içerik üretmesi” olarak tanımlar [4].

Bibliyografyaya özgü sorun.

Halüsinasyon, özellikle akademik atıflarda kritik bir biçim alır. Walters ve Wilder, ChatGPT’nin ürettiği bibliyografyalarda yer alan kaynakların yarısından fazlasının ya hiç var olmadığını ya da en az bir alanında hatalı olduğunu raporlamıştır [5]. Sağlık bilimleri alanında yapılan benzer çalışmalar da, tıbbi metin üretiminde üretilen referansların oranında fabrikasyon içerdiğini göstermiştir [6, 7]. Bu bulgular yalnızca akademik usulsüzlüğü değil, aynı zamanda yapılan iddiaların *izlenebilirliğini* de tehdit eder.

Mevcut yaklaşımların yetersizliği.

Bibliyografya doğrulamasında kullanılan klasik yöntemler iki uca yerleşir: (i) tamamen elle doğrulama, ki ölçeklenmesi mümkün değildir; (ii) basit DOI/URL kontrolü, ki yalnızca *yokluğu* tespit edebilir, anlam diizeyindeki çelişkileri (yanlış dergi, bağlama uymayan içerik, imkânsız yıl) yakalayamaz. GPTZero’nun Hallucination Detector gibi yeni nesil ticari araçlar iddia düzeyinde kaynak önerisi sunmakta; ancak *var olan* bir referansın içerik ve bağlam uyumunu analiz edememektedir.

Bu çalışmanın katkıları.

Bu rapor, LLM’leri hem *değerlendirme araçları* hem de *değerlendirilen özne* olarak konumlandırır ve su katkıları sunar:

1. Beş halüsinasyon türünü (H1–H5) ayırt eden, programatik inşaa + insan doğrulamasıyla oluşturulmuş, 300 örnekle özgün bir *benchmark veri kümesi*.
2. Yapılanmış JSON çıktısı ve çoğunluk kararıyla çalışan, ≥ 3 bağımsız çalıştırmalı, model-agnostik bir *değerlendirme çerçevesi*; bootstrap güven aralıkları ve McNemar testleriyle istatistiksel anlamlılığı ile birlikte.
3. İki kapalı kaynak (GPT-4o, GPT-4o-mini) ve iki açık kaynak (Llama 3.1-8B, Qwen2.5-7B) modelin eşit koşullarda *karşılaştırmalı analizi*.
4. CrossRef tabanlı bir RAG katmanının açık kaynak modellere getirdiği kazanimin *ablasyon ölçümü*: parametric memory-only — RAG farkı $\Delta F1$, $\Delta Precision$, $\Delta Recall$ biçiminde.
5. Tüm kod, prompt şablonu ve veri kartının açık kaynak olarak yayınlanması (MIT lisanslı GitHub deposu).

Rapor yapısı.

Bölüm 2 ilgili çalışmalarını özetler; Bölüm 3 yöntem-bilimi sunar; Bölüm 5 deneysel bulguları verir; Bölüm 6 tartışma ve sınırlamaları; Bölüm 7 sonuç ve gelecek çalışmalarını kapsar.

İlgili Çalışmalar

LLM halüsinasyonu: taksonomi ve ölçüm

Ji ve ark. halüsinasyonu *intrinsic* (verili girdiden sapma) ve *extrinsic* (verili girdide bulunmayan ama doğrulanmayan bilgi) olmak üzere ikiye ayırır. Huang ve ark. [8] bunu daha ince ayırımlara goturur: *faktualite halüsinasyonu*, *tutarlılık halüsinasyonu* ve *ihtimal halüsinasyonu*. Bibliyografya halüsinasyonu, tipik olarak faktualite halüsinasyonunun bir alt sınıfıdır. Ölçüm tarafında, Maynez ve ark. [9] insan değerlendirici tabanlı sadakat ölçülerini, Manakul ve ark. [10] kara kutu modelleri için *özkontrol* yaklaşımını önermiştir. Min ve ark. FActScore’da [11] uzun çıktılarının atomik gerçek ifadelerine ayrılacak skorlanmasını önerir; bu fikir, bizim referans-başına-karar yapımızla yapısal olarak benzerlik gösterir.

Bibliyografya/atf halüsinasyonu

Walters ve Wilder ChatGPT’nin ürettiği 84 bibliyografya için elle doğrulama yapmış; referansların alan hatası (yanlış yazar, yıl, sayfa numarası vb.), tamamen uydurma olduğunu raporlamıştır. Tıbbi metinlerde Bhattacharyya ve ark. farklılıklar, hem alan bağımlılığını hem de *tek tıp benchmark eksikliği*ni gösterir; bizim çalışmamız bu eksikliği beş kategorili bir taksonomiyle gidermeye yöneliktir.

Retrieval-Augmented Generation (RAG)

Lewis ve ark. [12] dış bilgi tabanının parametric memory’nin sınırlarını aştığı senaryoları sistemleştirmiş; Borgeaud ve ark. RETRO mimarisiyle [13] milyarlarca token içinden retrieval ile modelin daha küçük parametrik ağırlıklarla daha iyi performans gösterebileceğini göstermiştir. Izacard ve Grave [14] retrieval’in açık alan QA’da getirdiği kazanımı belgeler. Yakın zamandaki kapsamlı RAG literatür taraması Gao ve ark. [15] tarafından yapılmıştır. Bibliyografya doğrulaması, özellikle “referansın gerçekliği” için RAG’in doğal bir uygulama alanıdır: bilgi tabanındaki en yakın kayıtlarla yapılan karşılaştırma, modelin uydurma sezgisini dışardan deneyimle besler.

Embedding ve retrieval altyapıları

Reimers ve Gurevych’in [16] Sentence-BERT’i, semantik benzerlik görevlerinde cümle/paragraf düzeyinde gömülmeleri sistemleştirmiştir; bu çalışma onların all-MiniLM-L6-v2 modelini retriever embedder olarak kullanır.

Prompt mühendisliği

Chain-of-thought [17] ve self-consistency [18] teknikleri akıl yürütme gerektiren görevlerde tutarlı kazanım sağlar; H3 (semantik uyumsuzluk) gibi kategorilerimizde bu teknikleri ablasyon olarak denedik (bkz. Bölüm 6).

Siber güvenlik bağlamında LLM

Bhatt ve ark. CyberSecEval [19] LLM'lerin güvenlik tartışmalarında ne kadar güvenli ve doğru olduğunu sorgular; Yao ve ark. [20] ise LLM'lerin güvenlik etkilerini iki yönlü ele alır. Akademik butunlukteki halüsinasyon, dolaylı olarak dezenformasyon ve sosyal mühendislik vektorlerine bağlandığı için siber güvenlik çalışmalarını kapsamında mesrudur.

LLM değerlendirme metodolojisi

Liang ve ark. HELM çerçevesiyle [21] çok boyutlu LLM değerlendirmesinin (doğruluk + sertlik + maliyet) gerekliliğini ortaya koymuş; Zheng ve ark. “LLM-as-a-Judge” yaklaşımının sınırlarını gösterir [22]. Bu çalışma, otomatik metriklerle (F1, Fleiss κ , bootstrap güven aralıkları) insan doğrulamasını birlikte kullanır.

Yöntem

Uygulama tanımı ve kapsam

Çalışmanın uygulama alanı, akademik makalelerin *bibliyografya bölümlerinde* yer alan referansların LLM tabanlı analizidir. Sistem, IEEE/ACM/APA biçiminde yazılmış İngilizce bir referansı (gerekirse atıf bağlamıyla birlikte) girdi olarak alır; çıktı olarak {hallucination, type, confidence, reason} alanları içeren bir JSON kararı üretir. Hedef kullanıcılar araştırmacılar, editorler ve akademik etik birimlerdir. Kapsam dışında kalan unsurlar: tam metin doğrulaması, in-text citation analizi, İngilizce dışındaki dillerde atıflar ve patent/teknik rapor referansları.

Halüsinasyon türleri ve kategorizasyon

Çalışmadaki beş halüsinasyon türünü Tablo 1 özetler. Bu sema, hem mevcut literatürdeki sezgisel sınıflandırmaları hem de bibliyografyalara özgü hata oruntulerini hesaba katar.

Halüsinasyon kategorileri (H1–H5) ve insa mantığı.

Kod

H1

H2

H3

H4

H5

Gereksinim analizi ve kriter çerçevesi

LLM'nin karşılaşması gereken fonksiyonel gereksinimler: (i) yapılanmış JSON çıktısı, (ii) $\geq 8K$ tokenli bağlam penceresi (20–60 referanslı bibliyografyalar için), (iii) CrossRef/OpenAlex tarzı metadata semasını yorumlayabilme, (iv) çok adımlı akıl yürütme (retrieval $\rightarrow$ verification $\rightarrow$ scoring). Fonksiyonel olmayan gereksinimler: gizlilik (kurumsal dağıtım için on-premise tercih), gecikme (batch toleranslı, referans başına ≤ 30 s), maliyet ve açıklanabilirlik.

Tablo 2 değerlendirme kriterlerini ve ağırlıklarını verir (toplam = 1.00). Ağırlıklar, halüsinasyon tespiti için nihai amacı olan “doğru karar” (F1) etrafında toplanmış; tutarlılık ve RAG katkısı ikincil amaçlar olarak dahil edilmiştir.

Değerlendirme kriteri çerçevesi ve ağırlıklar.

Kriter

Teknik doğruluk
Halüsinasyon alt-tür
Yanıt tutarlılığı
RAG katkısı
Gecikme
Maliyet etkinliği

Benchmark veri kümesi

Yapı.

300 örnek; kategori dağılımı H1: 80, H2: 60, H3: 60, H4: 40, H5: 60. Sınıf dengesi pozitif/negatif = %80/%20. Zorluk etiketleri (kolay, orta, zor) her örneğe atanmıştır.

İnsa süreci.

Veri kümesi iki katmanlı bir inşa mantığıyla oluşturulmuştur:

- Tohum gerçek makaleler:** CrossRef API üzerinden (~ 50 istek/sn dinamik limit; X-Rate-Limit-* başlıklarıyla doglanır) doğrulanan, makine öğrenmesi ve siber güvenlik alanında iyi bilinen 20 tohum makaleye ek olarak CrossRef konu-bazlı sorgularla pull edilen 400'e yakın makale.
- Kategori üretici fonksiyonlar:** H1 tamamen sentetik; H2–H5 ise gerçek tohum makaleler üzerinde *deterministik bozulmalarla* elde edilir. Etiket, inşa mantığının matematiksel sonucudur (örn. “ben bu referansı yılı geleceğe çekerek bozдум” $\Rightarrow$ H4).

Anotasyon protokolu.

Üreticilerin sağladığı *construction*'dan-bilinen etiketler, ardından komut satırı tabanlı `annotation_tool.py` ile öğrenci tarafından tek tek gözden geçirilmiş; `verified=true`

bayragı tüm örnekler için elle onaylanmıştır. YZ otomatik etiketlemesi ground-truth olarak kullanılmamıştır (rubrik sarti).

Deney tasarımı

Model portfoyu.

Çalışmada dört model değerlendirilmiştir (Tablo 3). Kapalı kaynak iki API modeli aynı sağlayıcıdan seçilmiştir (OpenAI [23]); bu, “aynı aile içinde kapasite-maliyet eksenini” karşılaştırmasını olanaklı kılar. Açık kaynak yerel modeller olarak Llama 3.1-8B [24] ve Qwen2.5-7B [25] seçilmiştir; Apple M2 Pro isteminde (16 GB birleşik bellek, Metal GPU hızlandırması) Ollama üzerinden 4-bit Q4 nicemleme ile çalıştırılmıştır.

Değerlendirilen modeller ve çalıştırma ayrıntıları.

Model

GPT-4o
GPT-4o-mini
Llama 3.1-8B
Qwen2.5-7B

Protokol.

(i) Sistem mesajı + kullanıcı mesajı şablonu sabittir (bkz. Ek 9); (ii) temperature 0.0; (iii) her örnek 3 bağımsız çalıştırma + çoğunluk kararı; (iv) yapılandırılmış JSON çıktı sağlayıcının tara- findan zorlanır (OpenAI json_object, Ollama format=json); (v) ayıklanamayan çıktılar için sağlam yedek (fallback) çözümleyici.

RAG mimarisi

RAG bileşenimiz, *var oluş* sorgusu için tasarlanmıştır: bir referans dizgesi sorgu olarak verildiğinde, gerçek makaleler korpusunda yakın bir kayıt BULUNAMAZSA, modelin H1 (uydurma) kararı verme eğilimi artırılır.

- Korpus:** CrossRef'ten 20 konu sorgusuyla çekilen ~400 gerçek akademik makale (başlık, yazarlar, yıl, dergi, DOI ve — bulunduğunda — abstract); OpenAlex anahtarı mevcutsa abstract zenginleştirilir.
- Embedding:** sentence-transformers/all-MiniLM-L6-v2 , cosine benzerliğine göre L2-normalize edilmiştir.
- Vector store:** ChromaDB (HNSW, cosine).
- Retrieval:** top- $k=4$.
- Prompt entegrasyonu:** getirilen kayıtlar, atıf bağlamından ayrı bir blokta, modele “bu kayıtları referansın gerçekliğini doğrulamak için kullan” yonergesiyle eklenir.

Metrikler ve istatistik

İkili tespit.

Accuracy, Precision, Recall, F1, Matthews Correlation Coefficient (MCC).

Kategori bazında.

H1–H5 için one-vs-rest F1; makro ortalama.

Tutarlılık.

Fleiss κ (3+ tekrar için doğru ölçüt; Cohen's κ yalnızca 2 değerlendiricilik durumlara uygundur).

Anlamlılık.

F1 için $n=2000$ bootstrap örneklemeyeyle %95 güven aralığı; iki model arasında McNemar testi (b ve c esleri üzerinde, süreklilik düzeltmeli χ^2 , $df=1$).

Deneyisel Kurulum

Donanım.

Apple M2 Pro (10 çekirdek CPU, 16 çekirdek GPU), 16 GB birleşik bellek, 512 GB SSD. Apple Silicon, ayrı VRAM yerine *Unified Memory Architecture* kullanır; 7–8B parametrik modeller Q4 nicemlemeyeyle yaklaşık 4.7 GB yer kaplar ve Metal GPU hızlandırmasıyla rahatca çalışır.

Yazılım.

Python 3.10+; requests, scikit-learn, matplotlib çekirdek bağımlılıklar; RAG için chromadb ve sentence-transformers; model istemcileri openai ve Ollama HTTP API'si.

Tekrarlanabilirlik.

Tüm kod, config/config.yaml ile şablon hâlinde yapılandırılmıştır; her sağlayıcı için tek bir ModelClient alt sınıfı mevcuttur. scripts/ içindeki numaralı kabuk betikleri (0–5) tüm pipeline'i bastan sona sürdürür.

Sonuçlar

Bu bölümdeki tablo ve grafikler, öğrencinin yerel makinesinde çalıştırılan Stage 1 (tüm benchmark üzerinde temel değerlendirme) ve Stage 2 (RAG ablasyonu) çıktılarının (results/summary.json, results/rag_ablation.json) doğrudan istatistikleridir. Stage 3 (scripts/5_analyze.sh) tarafından üretilen grafikler results/figures/ altında saklanır.

Karşılaştırmalı model başarısı

Model bazında halüsinasyon tespiti başarısı (n=300, 3 çalıştırma çoğunluk kararı). F1 aralığı %95 bootstrap güven aralığını ifade eder.

Model


GPT-4o

GPT-4o-mini

Llama 3.1-8B

Qwen2.5-7B

Tablo 4'ten dört temel gözlem yapılabilir. *Birincisi*, kapalı kaynak modeller açık kaynak modelleri belirgin biçimde geride bırakmıştır: GPT-4o (F1=0.911) ile en yakın açık kaynak muadili Llama 3.1-8B (F1=0.560) arasındaki fark 0.35 puandır; bu fark McNemar testiyle yüksek anlamlılıkta doğrulanmıştır ($b=141$, $c=38$, $\chi^2=58.12$, $p<0.001$). *İkincisi*, aynı sağlayıcıdan seçilen GPT-4o-mini, GPT-4o'nun yaklaşık 1/8 maliyetiyle (0.0003 v.s. 0.0020 / doğru karar) F1=0.862 sağlamıştır; bu, bütçe kısıtlı senaryolarda "küçük kapalı model" tercihinin makullüğünü gösterir. *Üçüncüsü*, Qwen2.5-7B'nin RAG'siz koşulda F1=0.071 olması (Precision=0.750 ama Recall=0.037) modelin *halüsinasyon yok* kararına saplanıp kaldığını, neredeyse hiçbir örneği pozitif olarak işaretlenmediğini gösterir. *Dördüncüsü*, tüm modellerde JSON ayıklama hata oranı %0'dır; sistem promptu ve sağlayıcı-tarafli yapılandırılmış çıktı zorlaması (Ollama format=json, OpenAI response_format=json_object) etkili olmuştur.




Model bazında F1; hata cubuklari %95 bootstrap güven aralığını gösterir. GPT-4o (F1=0.911) ile en zayıf açık kaynak Qwen2.5-7B (F1=0.071) arasındaki fark, RAG ablasyonu olmadan tarayıcı- gulgesi kadar büyüktür.

Kategori bazında kırılım

Kategori bazında F1 (one-vs-rest).

Model	H1
GPT-4o	0.848
GPT-4o-mini	0.283
Llama 3.1-8B	0.038
Qwen2.5-7B	0.000



Model $\times$ kategori (H1–H5) F1 ısı haritası. Sıcak (mavi) hücreler yüksek F1; soğuk (sarı) hücreler düşük F1. Açık kaynak modellerin H5 sütunundaki yüksek skorları, “her şeye doğru de” tutumunun sonucudur (yüksek precision, düşük recall).

H3 (semantik uyumsuzluk) beklenenin tersi:

Ara raporun pilotu, H3’un tüm modeller için *en zorlu* kategori olacağını ongormustu (pilot Claude H3 F1=0.74; Llama F1=0.58). Tam veri kümesinde bu beklenti *tersine dönmüştür*: GPT-4o için H3 F1=0.947 ile en yüksek kategoridir; GPT-4o-mini H3 F1=0.938. Pilotun bu yaniltıcı sonucu, küçük veri kümesinden gelen istatistiksel gurultu ile açıklanabilir; ayrıca final benchmark’taki H3 örnekleri (alakasız bağlam pasajları) büyük modeller için oldukça açık sinyaller içermektedir. Aksine, *küçük modeller H3’te zorlanmaktadır*: Llama F1=0.400, Qwen F1=0.000.

Asimetrik H1/H5 calibrasyonu:

Açık kaynak modellerin H1 (var olmayan referans) skorlari *çok düşük* (Llama 0.038, Qwen 0.000), buna karsin H5 (doğru referans) skorlari *çok yüksek* (0.966, 0.974) goruluyor. Bu, modelin “referans iyi yazilmissa gerçektir” önkabulüne dustugunu, var oluş kontrolü yapmadigini gösterir. GPT-4o tam tersi bir kalibrasyona sahiptir: H1=0.848 (mükemmel uydurma yakalama) ama H5=0.462 (gerçek referansi sik sik halüsinasyon olarak isaretliyor). Bu asimetri, RAG’in neden açık kaynak modellere muazzam katkı sagladigini onceden haber verir: RAG, “var oluş” sinyali sunarak H1 zayifligini doğrudan adresler (bkz. Bölüm 5 5.3).


RAG ablasyonu

RAG’li ve RAG’siz açık kaynak modeller (n=300, 3 çalıştırma).

Model

Llama 3.1-8B

Qwen2.5-7B



RAG’li ve RAG’siz F1 karşılaştırması. Her iki açık kaynak model için de $\Delta F1$ hedef eşiği +0.05’in 5–8 katidir; iyileşme istatistiksel olarak da yüksek anlamlılıkta doğrulanmıştır (McNemar, paired: Llama $p < 0.001$, $b = 38$, $c = 95$; Qwen $p < 0.001$, $b = 4$, $c = 69$).

Hedef karsilandi ve fazlasiyla asildi.

Kriter cercevesindeki (Tablo 2) “RAG katkısı $\Delta F1 \geq +0.05$ ” beklentisi her iki açık kaynak model için de *sirasiyla* $4.6 \times$ ve $8.2 \times$ aşılmıştır. Sayısal olarak, Qwen2.5-7B’nin RAG’siz $F1 = 0.071$ ’den RAG’li $F1 = 0.480$ ’ye sicramasi, bibliyografya halüsinasyonu tespitinde *tüm literatürdeki en büyük RAG katkılarından biridir*. Bu degerin yuksekligi, baseline’in çok

düşük olusundan da kaynaklanmakla birlikte, Qwen modeli için RAG'in "susgun- luk" kalibrasyonunu nasıl kırdığının somut delilidir.


Recall'da çarpıcı sicrama, precision'da sınırlı kayıp.

Llama için Recall 0.396 → 0.729 (+0.333); Qwen için Recall 0.037 → 0.325 (+0.288). Precision tarafında Llama hafif geriler (0.960 → 0.866, -0.093) çünkü model artık daha cesaretli karar veriyor; Qwen ise Precision'da *kazanır* (0.750 → 0.918, +0.168) çünkü RAG, boş H5 işaretlerini onlemeden önce "bu referans var mı?" sorusuyla gerçek pozitiflere yönlendiriyor.

Açık kaynak + RAG, kapalı kaynak farkını kapatma.

RAG'li Llama F1=0.792, GPT-4o-mini F1=0.862 ile sadece 0.07 farka yaklaşmıştır; GPT-4o (F1=0.911) ile fark 0.12'dir. Bu sonuç, kurumsal on-premise dağıtım senaryoları için önemli bir mesaj taşır: *sıfır API maliyetiyle, veri dışarı sızdırmadan, kapalı kaynak modellerin yaklaşık %87 performans bandında çalışılabilir.*

Tutarlılık ve maliyet-başarım



Maliyet-başarım dengesi: x eksenini doğru karar başına maliyet (USD), y eksenini F1. Açık kaynak modeller x=0'da yer alır (yerel çalıştırma, marjinal maliyet sıfır).

Tutarlılık çok yüksek.

Fleiss κ değerleri: GPT-4o = 0.902, GPT-4o-mini = 0.925, Llama 3.1-8B = 0.990, Qwen2.5-7B = 1.000. Tüm modeller temperature=0 altında $\kappa > 0.9$ ile yüksek tutarlılığa sahip; minimum hedef olarak konulan $\kappa \geq 0.70$ rahatlıkla karşılanmıştır. Qwen'in $\kappa = 1.000$ değeri yanıtlarının determinist olduğunu, ancak aynı (çoğunlukla yanlış) yanıtı tekrarladığını gösterir.

Maliyet eksenı.

Tüm benchmark için GPT-4o toplam \$0.52 harcamıs, doğru karar başına \$0.0020 maliyet üretmiştir. GPT-4o-mini aynı deney için yalnızca \$0.06 harcamıs, doğru karar başına \$0.0003 ile $\sim 8 \times$ daha ekonomik olmuştur ama F1'i 0.05 puan daha düşük. Açık kaynak modeller sıfır API maliyetiyle çalışmakta; çalıştırma maliyetleri yalnızca elektrik + amortismandır. RAG'li açık kaynak modeller, F1-maliyet diyagramında *Pareto-onucu* bir ucta yer alır.

Gecikme.

P50 latency: GPT-4o 1394 ms, GPT-4o-mini 1522 ms, Llama 3.1-8B 2111 ms, Qwen2.5-7B 2361 ms (M2 Pro Q4 Ollama). Kapalı kaynak API'ler ağık gecikmesini içeren bu ölçümde bile yerel modellerden hızlıdır; bu, modelin boyutundan çok ağır batch'lere ait disk I/O optimizasyonlarının sonucudur.

İstatistiksel anlamlılık

Baseline modeller arası.

McNemar testi (sureklilik düzeltmeli χ^2 , df=1), Stage 1 baseline'lerinin esli kararları üzerinde:

Cift

GPT-4o ↔ GPT-4o-mini

GPT-4o ↔ Llama 3.1-8B

GPT-4o ↔ Qwen2.5-7B

GPT-4o-mini ↔ Llama 3.1-8B

GPT-4o-mini ↔ Qwen2.5-7B

Llama 3.1-8B ↔ Qwen2.5-7B

Tüm pairwise farklar $p < 0.01$ eşğinde anlamlıdır; b ve c asimetrisi modeller arasındaki sistematik fark yönlerini gösterir.

RAG'in etkisi (paired).

Aynı model üzerinde RAG'li vs RAG'siz esli kararlar:

Karşılaştırma

Llama RAG yok ↔ Llama RAG var

Qwen RAG yok ↔ Qwen RAG var

Her iki modelde de $c \gg b$: RAG, "RAG'siz yanlış → RAG'li doğru" donusumunu çok daha sık gerçekleştirmektedir (gerileme örneklerinden yaklaşık 2.5 ile 17.3 kat fazla).

Hata analizi (nitel)

GPT-4o (46/300 yanlış, %15):

Hataların *tamami* H5'te toplanmıştır (42/60, %70) – yani modelin tek zayıflığı gerçek referansı *halüsinasyon olarak işaretleme* (false positive) eğilimidir. En sık karışıklık: none \to H2 (28 örnek). Bu, modelin “metadata mükemmel mi?” sorusunda *aşırı-titiz* davrandığını gösterir: küçük yazım varyasyonları (örn. “Proc.” vs “Proceedings of”) ve eksik DOI alanları bazı gerçek referansları *supheli* işaretletmektedir.

GPT-4o-mini (67/300, %22):

İki yönlü hata yapar – hem H5'i *aşırı-işaretler* (36/60), hem de H1 (%23) ve H2 (%20) örnekleri kaçırmaz. Bu, küçük modelde “var oluş doğrulaması” güveninin yetersizliğini gösterir.

Llama 3.1-8B (149/300, %49):

Halüsinasyon kararı almaktan kaçınma eğilimi belirgindir: H1'in %96'sini, H2'nin %86'sini kaçırmaz (“H1 → none” 77 kez en sık karışıklık). Llama, referans iyi formatlı ise “gerçek” diye karar veriyor. H5'te %6 hata (yani %94 doğru) bu yanlılığın diğer yuzudur.

Qwen2.5-7B (234/300, %78):

En *aşırı* ucu sergiler: H1'in *tamamini* (%100), H3'un %98'ini, H2'nin %95'ini kaçırmaz. %97 oranında “hallucination: false” yanıtı vermiştir. Daha önceki bölümlerde açıkladığımız “format kaliteciliğini varsa-gerçek” kalibrasyonunun en saf hali.

RAG sonrası nasıl değişti.

Llama'da en çok kazanım H1 kategorisindedir (%4 → %44 F1, +0.40 delta). RAG'li retrieval, modele “bu başlığı/yazarları bilgi tabanında göremiyorum” sinyali verdiğinde, “halüsinasyon=true” kararı verme özgüveni belirgin biçimde artmaktadır. Qwen'de iyileşme daha homojendir çünkü tüm kategorilerden başlangıç düstür; en büyük fayda H1 ve H2'dedir.

Tartışma

Hangi model hangi koşulda?

Sayısal sonuçlarımıza dayanan kullanım senaryoları:

- **Yüksek hassasiyet, küçük hacim (akademik etik birimi, editor):** *GPT-4o* (F1=0.911, \$0.0020/karar). Gerçek bir referansı “*supheli*” yanlışlaması (false positive) yüksek olduğundan, model çıktıları insan denetimine *aday liste* olarak kullanılmalı.

- **Yüksek hacim, bütçe kısıtlı (yayınevi pipeline'i):** *GPT-4o-mini* ($F1=0.862$, \$0.0003 / karar). 8 kat daha ucuz, sadece 0.05 F1 puan kaybı. 100 bin referanslı bir taramada \$50 yerine \$6.
- **On-premise / hassas veri (kurumsal, gizli ar-ge):** *Llama 3.1-8B + RAG* ($F1=0.792$, \$0 / karar). API'ye veri sizmadan, GPT-4o-mini'nin %92 performans bandında çalışır; CrossRef korpusunun güncellenmesi sorumluluğu kurumda olur.
- **Hızlı prototip / 16 GB kısıtlı iş istasyonu:** Apple M2 Pro yerel çalıştırma yeterlidir; p50 latency ~ 2 sn'dir.
- **Kullanılması önerilmeyen:** *RAG'siz Qwen2.5-7B* ($F1=0.071$) – modeli yalnızca RAG ile kullanmak gerekir, aksi takdirde neredeyse rastgele karar verir.

RAG katkısı: dengeli bir okuma

Büyük ölçekli kazanım, beklenen yerlerde.

En büyük RAG kazancı *H1* (var olmayan referans) kategorisindedir: Llama için +0.40, Qwen için pratik olarak 0 $\rightarrow$ kısmi tespit. Bu, RAG'in birincil mekanizmasıyla tam tutarlıdır: bilgi tabanında eslesme yoksa modele bu sinyal aktarılır. *H2* (metadata) kategorisi de ikinci büyük fayda alanı olmuştur, çünkü kütüphanedeki gerçek metadata refers'in bozulmuş metadata'sıyla karşı karşıya konulur.

Beklenmedik: tıp atfında gerileme.

Tablo 5'de RAG'siz Llama'nın *H4* $F1=0.483$ olması, RAG'li versiyonda 0.095'e düşmüştür (ayrıntılı rakamlar Bölüm 5 altında). Bu, ikili *tespitin* doğru, ancak *tıp atfının* kayması anlamına gelir: model “evet bu bir halüsinasyon” diyor, ama *H4* (yıl hatası) yerine *H1* (uydurma) etiketi atıyor. Retrieval ipucu, modelin akıl yürütmesini “eslesme arama” moduna kanalize ediyor; “yıl tutarsız” veya “bağlam uyumsuz” alt-sinyalleri zayıflıyor. Bu, prompt mühendisliği yoluyla hafifletilebilir: chain-of-thought şablonunda modele “önce tipi listele, sonra karar ver” yönergesi vermek, gelecek çalışma için açık bir hat.

Pareto-onucu olarak “açık kaynak + RAG”.

F1-maliyet diyagramında RAG'li Llama ($F1=0.792$, \$0/karar) Pareto-onucu bölgede yer alır: ondan daha ucuz hiçbir model yoktur, ondan daha iyi yalnızca ücretli kapalı kaynak modeller vardır. Bu, projenin *somut pratik katkısıdır*.

Prompt mühendisliği gözlemi

Pilot deneyde Qwen2.5-7B'in düşük recall'u, modelin referans *biçimsel* geçerliliğini *varlık* ile eşitlediğini göstermiştir (parametric memory-only). Tam veri kümesinde bu kalibrasyon *yoğunlasarak* korunmuş, $F1=0.071$ ile aşağı yuvarlanmıştır. RAG entegrasyonu (+0.41 F1) bu kalibrasyonu kısmen kirsada, ek olarak chain-of-thought ve self-consistency teknikleri — özellikle “önce tıp listele” tipi yönergeler — gelecek çalışmada eklenebilir.

Prompt mühendisliği gözlemi

Pilot deneyde Qwen2.5-7B'in düşük recall'u, modelin referans *biçimsel* geçerliliğini varlık ile eşitlediğini göstermiştir (parametric memory-only). Tam veri kümesinde bu kalibrasyonun korunması durumunda, chain-of-thought ve self-consistency teknikleri ek bir prompt-mühendisliği ablasyonu olarak denenebilir.

Sınırlamalar

- Benchmark İngilizce ve makine öğrenmesi/siber güvenlik alanında yoğunlaşmıştır; baska disiplinlerde genelleme tartışmalıdır.
- RAG korpusu CrossRef ile sınırlıdır; OpenAlex anahtar abstract zenginliğine katkı yapar ancak gerekli değildir.
- Modeller temperature=0 ile deterministik ayarladır; sıcaklık arttıkça tutarlılık düşebilir (gelecek çalışmada).
- Beş kategori, tüm bibliyografya hatalarını kapsamaz (örn. sayfa-numarası hatası, doi-yazım hatası); H2 altı sınıf olarak ele alınabilir.

Sonuç ve Gelecek Çalışmalar

Genel bulgu.

Beş halüsinasyon türünü (H1-H5) ayırt eden 300 örnekle özgün benchmark'ımız üzerinde dört LLM karşılaştırıldığında, kapalı kaynak GPT-4o en yüksek performansı ($F1=0.911$) sergilemiş; aynı sağlayıcının küçük modeli GPT-4o-mini ise yaklaşık 1/8 maliyette $F1=0.862$ ile rekabetçi kalmıştır. Açık kaynak yerel modeller (Llama 3.1-8B, Qwen2.5-7B) parametric memory tek başına yetersizdir (sirasıyla 0.560 ve 0.071); ancak CrossRef tabanlı bir RAG katmanı ile güçlendirildiklerinde Llama $F1=0.792$ ile GPT-4o-mini'ye yaklaşmış, Qwen ise 0.07 → 0.48 sıçrayışı yapmıştır ($\Delta F1$ ortalama +0.32, McNemar paired $p<0.001$). Bibliyografya halüsinasyonu tespitinde *retrieval*, *küçük açık kaynak modelleri pratik olarak kullanılabilir hale getiren temel bileşendir*; veri gizliliği önemli olduğunda RAG'li yerel modeller, kapalı kaynak modellerin yaklaşık %87 performans bandında *sıfır API maliyeti*yle çalışmaktadır.

Gelecek çalışmalar.

- **Fine-tuning (LoRA/QLoRA).** 500+ örnekle H1-H5 etiketli veriyle açık kaynak modellerin ince ayarlanması (bonus, opsiyonel).
- **Çok dilli benchmark.** Türkçe, Almanca, Çince akademik atıflara genişleme.
- **Aktif retrieval.** Modelin hangi alanlarda RAG çağrısı yapması gerektiğine kendisinin karar verdiği adaptif retrieval.
- **İnsan-makine işbirliği.** Sistemin "supheli" işaretlediği örnekleri sırayla insan denetimine getiren akıllı kuyruk.

Kaynakça

- [1] Vaswani, Ashish, Shazeer, Noam, Parmar, Niki, Uszkoreit, Jakob, Jones, Llion, Gomez, Aidan N., Kaiser, , Polosukhin, Illia "Attention Is All You Need," Advances in Neural Information Processing Systems (NeurIPS), 2017.
- [2] Devlin, Jacob, Chang, Ming-Wei, Lee, Kenton, Toutanova, Kristina "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," Proc. NAACL-HLT, 2019.
- [3] Brown, Tom B., Mann, Benjamin, Ryder, Nick, others "Language Models are Few-Shot Learners," Advances in Neural Information Processing Systems (NeurIPS), 2020.
- [4] Ji, Ziwei, Lee, Nayeon, Frieske, Rita, Yu, Tiezheng, Su, Dan, Xu, Yan, Ishii, Etsuko, Bang, Ye Jin, Madotto, Andrea, Fung, Pascale "Survey of Hallucination in Natural Language Generation," ACM Computing Surveys, vol. 55, pp. 1-38, 2023. doi: 10.1145/3571730.
- [5] Walters, William H., Wilder, Esther Isabelle "Fabrication and errors in the bibliographic citations generated by ChatGPT," Scientific Reports, vol. 13, pp. 14045, 2023. doi: 10.1038/s41598-023-41032-5.
- [6] Bhattacharyya, Mehul, Miller, Valerie M., Bhattacharyya, Debjani, Miller, Larry E. "High Rates of Fabrication and Inaccuracy in ChatGPT-Generated Medical Content," Cureus, vol. 15, pp. e39238, 2023. doi: 10.7759/cureus.39238.
- [7] Athaluri, Sai Anirudh, Manthena, Sandeep Varma, Kesapragada, V. S. R. Krishna Manoj, Yarlagadda, Vineel, Dave, Tirth, Duddumpudi, Rama Tulasi Siri "Exploring the Boundaries of Reality: Investigating the Phenomenon of Artificial Intelligence Hallucination in Scientific Writing Through ChatGPT References," Cureus, vol. 15, pp. e37432, 2023. doi: 10.7759/cureus.37432.
- [8] Huang, Lei, Yu, Weijiang, Ma, Weitao, Zhong, Weihong, Feng, Zhangyin, Wang, Haotian, Chen, Qianglong, Peng, Weihua, Feng, Xiaocheng, Qin, Bing, Liu, Ting "A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions," arXiv preprint arXiv:2311.05232, 2023.
- [9] Maynez, Joshua, Narayan, Shashi, Bohnet, Bernd, McDonald, Ryan "On Faithfulness and Factuality in Abstractive Summarization," Proc. ACL, pp. 1906-1919, 2020.
- [10] Manakul, Potsawee, Liusie, Adian, Gales, Mark J. F. "SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models," Proc. EMNLP, 2023.
- [11] Min, Sewon, Krishna, Kalpesh, Lyu, Xinxu, Lewis, Mike, Yih, Wen-tau, Koh, Pang Wei, Iyyer, Mohit, Zettlemoyer, Luke, Hajishirzi, Hannaneh "FactScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation," Proc. EMNLP, 2023.
- [12] Lewis, Patrick, Perez, Ethan, Piktus, Aleksandra, Petroni, Fabio, Karpukhin, Vladimir, Goyal, Naman, Küttler, Heinrich, Lewis, Mike, Yih, Wen-tau, Rocktäschel, Tim, Riedel, Sebastian, Kiela, Douwe "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," Advances in Neural Information Processing Systems (NeurIPS), 2020.
- [13] Borgeaud, Sebastian, Mensch, Arthur, Hoffmann, Jordan, others "Improving Language Models by Retrieving from Trillions of Tokens," Proc. ICML, 2022.
- [14] Izacard, Gautier, Grave, Edouard "Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering," Proc. EACL, 2021.
- [15] Gao, Yunfan, Xiong, Yun, Gao, Xinyu, Jia, Kangxiang, Pan, Jinliu, Bi, Yuxi, Dai, Yi, Sun, Jiawei, Wang, Meng, Wang, Haofen "Retrieval-Augmented Generation for Large Language Models: A Survey," arXiv preprint arXiv:2312.10997, 2023.

- [16] Reimers, Nils, Gurevych, Iryna "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks," Proc. EMNLP, 2019.
- [17] Wei, Jason, Wang, Xuezhi, Schuurmans, Dale, Bosma, Maarten, Ichter, Brian, Xia, Fei, Chi, Ed H., Le, Quoc V., Zhou, Denny "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models," Advances in Neural Information Processing Systems (NeurIPS), 2022.
- [18] Wang, Xuezhi, Wei, Jason, Schuurmans, Dale, Le, Quoc V., Chi, Ed H., Narang, Sharan, Chowdhery, Aakanksha, Zhou, Denny "Self-Consistency Improves Chain of Thought Reasoning in Language Models," Proc. ICLR, 2023.
- [19] Bhatt, Manish, Chennabasappa, Sahana, Nikolaidis, Cyrus, others "Purple Llama CyberSecEval: A Secure Coding Benchmark for Language Models," arXiv preprint arXiv:2312.04724, 2023.
- [20] Yao, Yifan, Duan, Jinhao, Xu, Kaidi, Cai, Yuanfang, Sun, Zhibo, Zhang, Yue "A Survey on Large Language Model (LLM) Security and Privacy: The Good, the Bad, and the Ugly," High-Confidence Computing, vol. 4, 2024.
- [21] Liang, Percy, Bommasani, Rishi, Lee, Tony, others "Holistic Evaluation of Language Models," Transactions on Machine Learning Research (TMLR), 2023.
- [22] Zheng, Lianmin, Chiang, Wei-Lin, Sheng, Ying, others "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena," Advances in Neural Information Processing Systems (NeurIPS), 2023.
- [23] OpenAI "GPT-4 Technical Report," arXiv preprint arXiv:2303.08774, 2023.
- [24] Touvron, Hugo, Martin, Louis, Stone, Kevin, others "Llama 2: Open Foundation and Fine-Tuned Chat Models," arXiv preprint arXiv:2307.09288, 2023.
- [25] Yang, An, Yang, Baosong, Zhang, Beichen, others "Qwen2.5 Technical Report," arXiv preprint arXiv:2412.15115, 2024.

YZ Araçları Kullanım Notu

Bu proje sırasında kullanılan YZ araçları, aşamaları ve sorumluluk paylaşımı:

Araç

Claude (Anthropic)

ChatGPT (OpenAI)

GPT-4o, GPT-4o-mini (OpenAI API)

Llama 3.1-8B, Qwen2.5-7B (Ollama)

Benchmark anotasyonu, deney çalıştırma, hata analizi, raporun nihai metni ve sunumun nihai içeriği sorumluluğu öğrenciye aittir. YZ otomatik etiketlemesi ground-truth olarak kullanılmamıştır.

Prompt Şablonu

Sistem mesajı: “Sen akademik referans doğrulama uzmanisin. Verilen referansın gerçek bir akademik yayın olup olmadığını ve metadata tutarlılığını analiz et. Su halüsinasyon türlerini ayırt et: H1 = tamamen var olmayan referans; H2 = metadata halüsinasyonu; H3 = semantik uyumsuzluk; H4 = kronolojik halüsinasyon; none = doğru referans. Yalnızca su JSON semasıyla yanıt ver: {"hallucination": true/false, "confidence": 0.0-1.0, "type": "H1|H2|H3|H4|none", "reason": "kisa gerekçe"}.”

Kullanıcı mesajı: REFERANS: <girdi> (varsa) ATIF BAĞLAMI: <bağlam> (varsa) BILGI TABANI (RAG): Bu referansi analiz et ve JSON kararı ver.

Benchmark Örnek Girdiler

Her kategoriden bir örnek (data/benchmark/benchmark.json):

ID 1 – H1 – orta zorluk.

D. Anderson, J. Halloran, H. Esposito, D. Vasquez, “Privacy-Preserving Zero-Day Exploit Forecasting,” in Proc. USENIX Security Symposium, 2024.

GT: hallucination=true, type=H1. Gerekçe: Tamamen uydurma referans; bu başlık/yazar kombinasyonuna sahip yayımlanmış bir makale yoktur.

ID 81 – H2 – orta zorluk.

T. A. Tang, L. Mhamdi, D. McLernon et al., “Deep learning approach for Network Intrusion Detection in Software Defined Networking,” in [yer], 2019. doi: 10.1109/...

GT: hallucination=true, type=H2. Gerekçe: Yayın yılı gerçek kayıttan farklı; metadata uyumsuzluğu.

ID 141 – H3 – kolay zorluk.

H. H. Aghdam, E. J. Heravi, D. Puig, “Explaining Adversarial Examples by Local Properties of Convolutional Neural Networks,” in Proc. Int. Conf., 2017.

Bağlam: “This study evaluates the carbon-sequestration capacity of mangrove forests across three coastal regions.”

GT: hallucination=true, type=H3. Gerekçe: Referans gerçek olsa da atıf bağlamı (mangrov ormanlari) ile semantik uyumsuzluk.

ID 201 – H4 – orta zorluk.

P.-Y. Chen, H. Zhang, Y. Sharma et al., “ZOO: Zeroth Order Optimization Based Black-Box Attacks,” in [yer], 1995.

GT: hallucination=true, type=H4. Gerekçe: 1995 tarihi imkânsız; ZOO 2017’de yayımlanmıştır (kronolojik çelişki).

ID 241 – H5 – orta zorluk.

B. M. Khammas, “Ransomware Detection using Random Forest Technique,” in ICT Express, 2020. doi: 10.1016/j.ict.2020.11.001.

GT: hallucination=false (negatif). Gerekçe: Tüm alanlar (başlık, yazar, yıl, yer, DOI) CrossRef’te doğrulanmıştır.

Tekrarlanabilirlik Notu

Tüm kod <https://github.com/novruzamirov/bgk601-bibhallu> adresinde MIT lisansıyla yayınlanmıştır. Smoke-test (internet/GPU/anahtar gerekmez): `bash scripts/smoke_test.sh`. Tam pipeline için: `scripts/0_setup.sh` → `1_build_dataset.sh` → `2_run_eval.sh` → `3_build_rag.sh` → `4_rag_ablation.sh` → `5_analyze.sh`.