

Araştırma Makalelerinde

Bibliyografya Halüsinasyonlarının LLM Tabanlı Tespiti

Çok Modelli Karşılaştırmalı Değerlendirme ve RAG Ablasyonu

Novruz Amirov (707241004)

İstanbul Teknik Üniversitesi · Siber Güvenlik Mühendisliği ve Kriptografi Ana Bilim Dalı

Ders Koordinatörü: Prof. Dr. Kemal Bıçakçı

BGK601 · Bilgi Güvenliği Alanında Makine Öğrenmesi Yöntemleri · Bahar 2025–2026

Problem ve Motivasyon

LLM destekli akademik üretim, var olmayan veya hatalı bibliyografya atıflarını yaygınlaştırdı.

%55

ChatGPT bibliyografyalarında en az bir alan hatası

%47-73

Tıbbi metinlerde uydurma referans oranı

%0

Mevcut DOI denetleyiciler semantik hatayı yakalayabiliyor

Sonuç: Semantik düzeyde, ölçeklenebilir bir LLM tabanlı tespit hattına ihtiyaç var.

Kaynak: Walters & Wilder (2023), Bhattacharyya ve ark. (2023), Athaluri ve ark. (2023).

Halüsinasyon Kategorileri (H1–H5)

H1

Var Olmayan Referans

LLM tarafından üretilmiş, hiç yayımlanmamış makale

H2

Metadata Halüsinasyonu

Var olan makale; yanlış yazar / yıl / dergi

H3

Semantik Uyumsuzluk

Gerçek makale; atıf bağlamıyla anlamsal ilgisiz

H4

Kronolojik Halüsinasyon

İmkânsız tarih (gelecek veya teknolojidenden önce)

H5

Doğru Referans (Negatif)

Tüm alanlar doğrulanmış; halüsinasyon yok

Kullanım Senaryoları

No	Girdi	Başarı Kriteri
S1	20-referanslı bibliyografya doğrulama	F1 $\geq$ 0.80 doğrulama başarısı
S2	CrossRef DOI'li ama yanlış yazarlı referans	Metadata hata tespiti $\geq$ %85
S3	Yanlış dergiye atfedilmiş gerçek makale	Yayın yeri tespiti $\geq$ %80
S4	Makale içeriğiyle ilgisiz atf	Semantik uyum skoru $<$ 0.5 için uyarı
S5	Tüm metadata doğru ama yıl hatalı	Yıl hatası $\geq$ %90 doğruluk

Her senaryo, projenin değerlendirme rubriğindeki F1 hedef eşikleriyle eşlenmiştir.

Mevcut Yaklaşımların Yetersizliği

Elle Doğrulama

✗ Yavaş, ölçeklenmiyor

✓ İnsan uzman yargısı

Basit DOI/URL Kontrolü

✗ Anlam düzeyindeki hatayı (H2/H3) göremez

✓ Otomatik, hızlı


Ticari Araçlar (örn. GPTZero)

✗ Var olan referansın bağlam uyumunu ölçemez

✓ Kapalı iddia düzeyinde kaynak önerisi


Bu boşluk semantik anlama dayalı çok-katmanlı LLM tabanlı bir tespit ihtiyacı doğurur.

Sistem Mimarisi



Benchmark Veri Kümesi (300 örnek)

Kategori Dağılımı



İnşa Süreci

1. CrossRef API + 20 tohum makale ve 400+ gerçek kayıt
2. Construction'dan-bilinen ground-truth ile H1-H5 üretimi
3. `annotation_tool.py` ile her örnek elle insan onayı
4. Sınıf dengesi: %80 pozitif / %20 negatif
5. Zorluk etiketi: K / O / Z dengeli dağılım

YZ otomatik etiketleme ground-truth olarak KULLANILMADI.

Değerlendirme Kriterleri ve Ağırlıklar

Kriter	Ölçüm Yöntemi	Ağırlık
Teknik Doğruluk	F1, Precision, Recall	35%
Halüsinasyon Alt-Tür	5 kategori bazında F1	25%
RAG Katkısı	RAG ile/RAG'sız ablasyon ($\Delta F1$)	15%
Yanıt Tutarlılığı	3 bağımsız çalıştırma (Fleiss κ)	10%
Maliyet Etkinliği	USD / doğru karar	10%
Gecikme	p50 / p95 ms	5%

Toplam ağırlık: %100

Model Portföyü: 4 Model, 2 Tür

GPT-4o

OpenAI · Closed-source API

Maliyet: \$0.005/1K tok

GPT-4o-mini

OpenAI · Closed-source API

Maliyet: \$0.0006/1K tok

Llama 3.1-8B

Meta · Open-source (Ollama)

Maliyet: \$0 (yerel)

Qwen2.5-7B

Alibaba · Open-source (Ollama)

Maliyet: \$0 (yerel)

Yerel modeller Apple M2 Pro · 16 GB birleşik bellek · Q4_K_M nicemleme ile çalıştırıldı.

Değerlendirme Protokolü

T=0

Sıcaklık (temperature) 0 — deterministik

×3

Her örnek 3 bağımsız çalıştırma • çoğunluk kararı

JSON

Yapılandırılmış çıktı zorlanır (json_object / format=json)

n=300

Tam benchmark üzerinde değerlendirme

Fleiss κ

Çalıştırmalar arası tutarlılık (Cohen κ değil)


Bootstrap

F1 için %95 GA • 2000 örnekleme

McNemar

Eşli model karşılaştırması, χ^2 (df=1)

RAG Mimarisi (CrossRef → ChromaDB)



Anahtar fikir:

Bilgi tabanında yakın kayıt bulunamazsa (düşük cosine benzerliği) → referans muhtemelen uydurma (H1). Yüksek başlık-eşleşmesi + metadata uyumsuzluğu → H2/H4.

Ana Sonuçlar: 4 Model • 300 Örnek

Model	Acc	Precision	Recall	F1	USD / doğru
GPT-4o	0.847	0.849	0.983	0.911	0.0020
GPT-4o-mini	0.777	0.853	0.871	0.862	0.0003
Llama 3.1-8B	0.503	0.960	0.396	0.560	0.0000
Qwen2.5-7B	0.220	0.750	0.037	0.071	0.0000

? GPT-4o

F1 = 0.911 (lider)
McNemar farkı tümüne karşı $p < 0.001$

? GPT-4o-mini


F1 = 0.862 • 8× daha ucuz
Bütçe-duyarlı senaryolar için tercih

⚠ Qwen2.5-7B (RAG'sız)

F1 = 0.071 • Recall 0.037
"Halüsinasyon yok" deyip her şeyi onaylıyor

RAG Ablasyonu: En Güçlü Bulgu

F1 Skoru — RAG'sız vs RAG'lı



Δ F1 kazanımı

Llama 3.1-8B

+0.231

Hedefin 4.6 katı


Qwen2.5-7B

+0.409

Hedefin 8.2 katı — 0.071 → 0.480

McNemar paired test — Llama: $p < 0.001$ ($b=38$, $c=95$) · Qwen: $p < 0.001$ ($b=4$, $c=69$)

Kategori Bazında F1 (H1-H5)



Beklenmedik bulgu

H3 (semantik uyumsuzluk) büyük kapalı modeller için en kolay kategori oldu (0.94-0.95).

Ara raporun tersine, pilot ölçek gürültüsü

Açık kaynak modellerin H1 (uydurma) zaafı

- Llama H1 F1 = 0.038
 - Qwen H1 F1 = 0.000
- RAG ile bu zaaf doğrudan adreslenir.

İstatistiksel Anlamlılık (McNemar)

Karşılaştırma	b	c	χ^2	p	
GPT-4o ↔ GPT-4o-mini	31	10	9.76	0.0018	**
GPT-4o ↔ Llama 3.1-8B	141	38	58.12	$<10^{-4}$	***
GPT-4o ↔ Qwen2.5-7B	227	39	131.46	$<10^{-4}$	***
GPT-4o-mini ↔ Llama 3.1-8B	114	32	44.94	$<10^{-4}$	***
GPT-4o-mini ↔ Qwen2.5-7B	200	33	118.27	$<10^{-4}$	***
Llama 3.1-8B ↔ Qwen2.5-7B	87	2	79.28	$<10^{-4}$	***

Tüm pairwise farklar $p < 0.01$ düzeyinde anlamlı. Fleiss κ (3 çalıştırma) tüm modellerde 0.90 — 1.00 aralığında.

Hata Analizi (Stage 1 baseline)

GPT-4o

46/300 (%15)

H5 over-flag (false positive %70) · format-takıntılı

GPT-4o-mini

67/300 (%22)

H1 ve H5'te hata; küçük modelde "var olma" güveni düşük

Llama 3.1-8B

149/300 (%49)


H1 %96 kaçırma — "iyi formatlı → gerçek" varsayımı

Qwen2.5-7B

234/300 (%78)

%97'sinde "hallucination: false" diyor; tam susgunluk

Maliyet-Başarım Dengesi



Pareto önü

- Açık kaynak modeller $x=\$0$
- RAG'lı Llama F1 = 0.792
→ \$0 maliyetle GPT-4o-mini'ye 0.07 fark

Önemli mesaj

On-premise / hassas veri senaryolarında, açık kaynak + RAG yaklaşık %87 performans bandında çalışır.

Hangi Model Hangi Koşulda?

Yüksek Hassasiyet • Küçük Hacim

GPT-4o

F1=0.911 • \$0.0020/karar • İnsan denetimine aday liste

Yüksek Hacim • Bütçe Kısıtlı

GPT-4o-mini

F1=0.862 • 8× daha ucuz • 100k referans → ~\$6

On-Premise • Hassas Veri

Llama 3.1-8B + RAG

F1=0.792 • API'ye veri sızmadan • sıfır marjinal maliyet

Kullanma — RAG'sız Qwen

Qwen2.5-7B (yalnız)

F1=0.071 • neredeyse rastgele • yalnız RAG ile değerli

Sınırlamalar ve Gelecek Çalışmalar

Sınırlamalar

- Benchmark İngilizce ve ML / siber güvenlik alanında yoğun
- RAG korpusu CrossRef ile sınırlı (~400 makale)
- T=0 deterministik ayar — sıcaklık etkisi araştırılmadı
- 5 kategori tüm hata türlerini kapsamıyor (örn. sayfa, DOI)
- RAG, tip atfını bozdu (binary detect ↑ , type classify ↓)

Gelecek Çalışmalar

- LoRA / QLoRA ince ayarı (500+ örnekle H1-H5 etiketli veri)
- Çok dilli benchmark (TR, DE, ZH)
- Adaptif retrieval — model kendi karar verir
- Chain-of-thought + self-consistency prompt mühendisliği
- İnsan-makine işbirliği akıllı şüphe kuyruğu

Teşekkürler

Sorular & Canlı Demo

Canlı Demo Bileşenleri

- Aynı referans üzerinde GPT-4o vs Llama 3.1-8B + RAG canlı karşılaştırma
- RAG retrieval'in top-4 sonucu — semantik benzerlik skorları
- 300-örnekli benchmark üzerinde sonuç dashboard'u
- Tek bir uydurma referansın H1 olarak yakalanışı (RAG ile)

G i t H u b : [github.com /novruzamirov/bgk601-bibhalla](https://github.com/novruzamirov/bgk601-bibhalla)